

## 進捗報告

### 1 今週やったこと

- GA の実験
- 論文の再調査

### 2 GA の実験

表 1, 2 に実験の設定を示す。遺伝子は 0 から 9 の整数値をとる整数値コーディングとした。

選択はサイズ 2 のトーナメント選択, 交叉には二点交叉, 突然変異は別の数値にランダムに移るように設定した。

また, 今回事前学習したモデルを初期モデルとして学習させた。前回言われていたように, softmax 値から初期個体を生成した。

表 1: GA の設定

個体数	20
世代数	13
交叉率	1.0
突然変異率	0.02
labeled	250 枚
search	100 枚

#### 2.1 結果

図 1, 2 に示す。正答数が下がっているのは分かるが, 適応度に関してもかなりばらつきがあり, 初期個体に比べ下がってしまっていることがわかる。

### 3 論文の再調査

先々週にも軽く紹介したが, 半教師あり学習 (Semi Supervised Learning: semi-SL) に対し, 自己教師あり学習 (Self Supervised Learning: self-SL) という自動で生成できる情報によって特徴マップを学習する手法を取り入れたものが性能を示している。

表 2: FixMatch の設定

model	WideResNet16-2	
data set	cifar10	
batch size	labeled	32
	unlabeled	32 * 7
optimizer	SGD(lr=0.1,momntum=0.9)	
loss	cross_entropy_loss	
事前学習		
train	labeled	100
	unlabeled	49650
val data	150	
num.iterations	2**16	
GA の評価		
train	search のみ	100
	unlabeled	49650
val data	250	
num.iterations	5000	

#### 3.1 対象学習 (Contrastive Learning: CL)

CL は同じ画像の異なる変換画像から得られる特徴マップを一致するように, また, 異なる画像の特徴マップから離れさせるように学習する手法である。

#### 3.2 A Simple Framework for Contrastive Learning of Visual Representations (:SimCLR)

SimCLR は encoder, projection head を CL を用いて学習し, 得られたエンコーダに MLP などの分類器をつけてラベル付きデータでファインチューニングをするものである。また, 精度を出すためにはエンコーダもバッチサイズも非常に大きなものが必要となる。

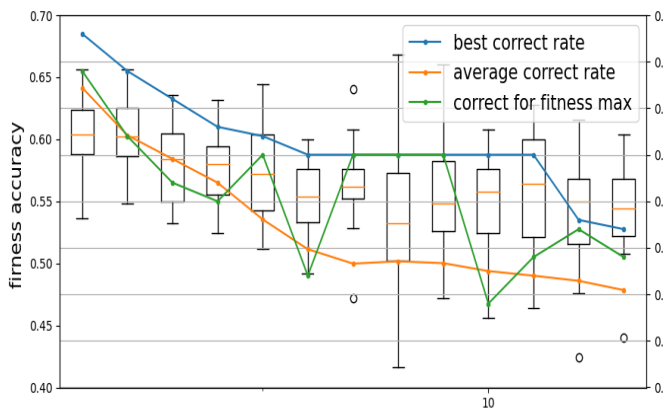


図 1: 実験 1 の結果

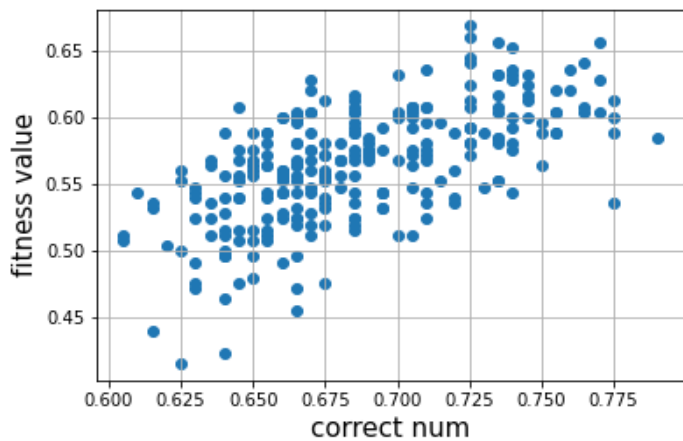


図 2: 実験 1 の相関図

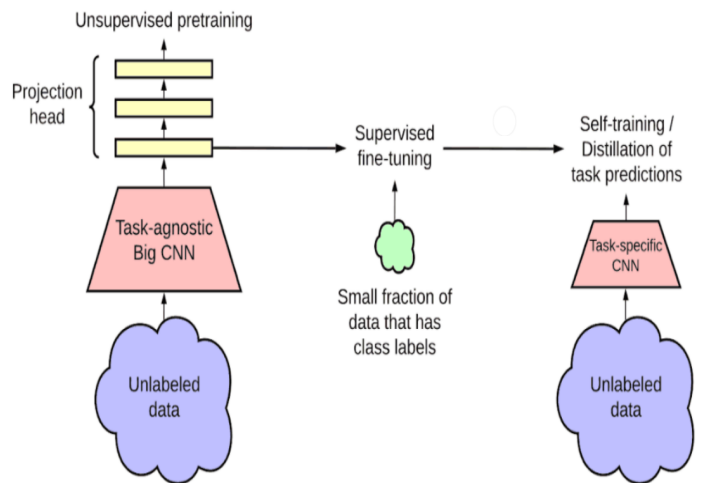


図 3: SimCLR の概略図




図 4: EnAET の概略図

### 3.3 Ensemble AutoEncoding Transformers(:EnAET)

EnAET はエンコーダ部が一つでデコーダ部が複数の AutoEncoder を用いて学習を行う。

### 3.4 CoMatch

CoMatch は SimCLR における projection head と分類器を同時に学習させていく手法で、その際に FixMatch の疑似ラベルを用いて学習する。また、非常に大きいバッチサイズを解決するために、Momentum Contrastive Learning を用いる。

## 4 来週の課題

- 実験設定の改良

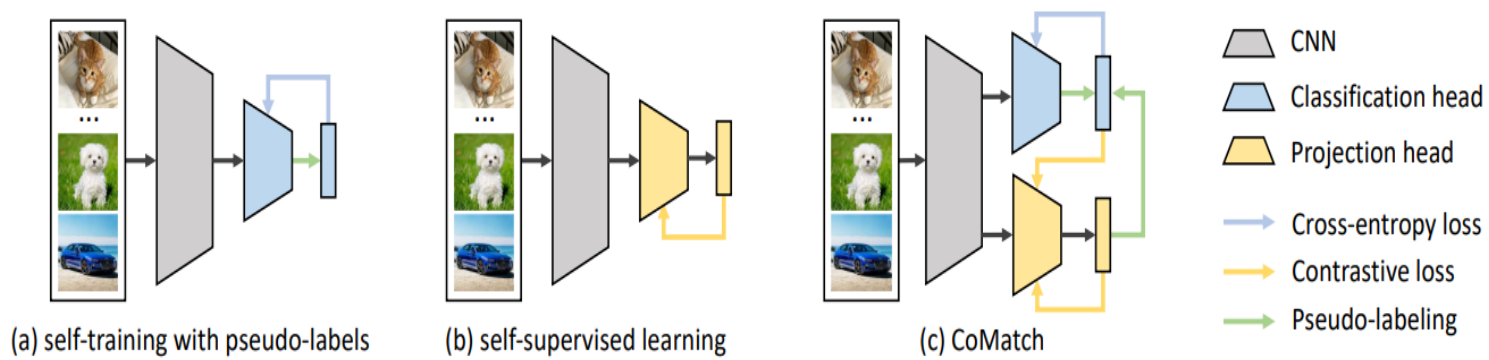


図 5: CoMatch の概略図